

PIPELINE PREDITIVO

Aplicado à Indústria 4.0

Isabela Gomes da Costa
Desenvolvimento de IA para Análise Preditiva
T3 | Módulo 01



MANUTENÇÃO PREDITIVA

- Previsão de falhas em equipamentos industriais;
- **Alvo:** falha_maquina – 0: normal; 1: falha;
- Comparação entre KNN e Árvore de Decisão.

Amostra da base de manutenção preditiva

Primeiros cinco registros da base original

Temp. ar (K)	Temp. processo (K)	Rotação (RPM)	Torque (Nm)	Desgaste (min)	Falha (0 ou 1)
298,1	308,6	1551,0	42,8	0	0
298,2	308,7	1408,0	46,3	3	0
298,1	308,5	1498,0	49,4	5	0
NaN	NaN	NaN	NaN	7	0
298,2	308,7	1408,0	40,0	9	0

Falha: 0 = funcionamento normal | NaN = medição ausente

1 OBJETIVO

ORGANIZAÇÃO

- **Referências:** enunciado, anotações da Engenharia e notebooks das aulas;
- **Etapas:** análise, limpeza, criação de variáveis, divisão e balanceamento, escalonamento, ajustes e avaliação;

Organização das branches do projeto

Uma branch para cada fase do pipeline

Branch	Finalidade
main	Versão final do projeto
develop	Integração das etapas de desenvolvimento
1_analise_exploratoria	Inspeção, estatísticas e visualizações
2_limpeza_e_tratamento_de_dados	Duplicatas, nulos e análise de outliers
3-feature_engineering	Potência e diferença de temperatura
4_divisao_e_balanceamento_dos_dados	Treino/teste e balanceamento com SMOTENC
5_escalamento_de_variaveis	Codificação de tipo e escala para o KNN
6_ajuste_de_parametros_e_combate_ao_overfitting	Variação de K e profundidade da Árvore
7_avaliacao_da_acuracia_e_veredito_final	Comparação de métricas e seleção do modelo

Branches existentes e seus papéis no projeto; a imagem não representa o histórico de merges.


2 ORGANIZAÇÃO DO DESENVOLVIMENTO E BRANCHES

ANÁLISE EXPLORATÓRIA

- **10.000** registros e **14** colunas;
- **339** falhas;
- **500** linhas com sensores **ausentes**;
- **Fluxo principal**: remoção;
- **Comparativo**: mediana;
- Valores extremos preservados para investigação.

Distribuição da variável alvo

10.000 registros na base original



Apenas 3,39% dos registros apresentam falha: forte desbalanceamento das classes.

3 ANÁLISE E TRATAMENTO DOS DADOS

FEATURE ENGINEERING

- $\text{potencia} = \text{rotação} \times \text{torque}$;
- $\text{diferença térmica} = \text{temperatura do processo} - \text{temperatura do ar}$;
- **Divisão estratificada:** 80% treino e 20% teste;
- **SMOTENC** exclusivamente no treino;
- **KNN:** sensores escalonados;
- **Árvore:** sensores na escala original.


4 NOVAS VARIÁVEIS E PREPARAÇÃO

AJUSTE DOS MODELOS

Modelo	Configurações avaliadas	Melhor acurácia de teste
KNN	K = 3, 5 e 7	K = 3
Árvore	Profundidade 3, 5 e sem limite	Sem limite

- **Árvore sem limite:** 100,00% no treino e 95,89% no teste, na base principal;
- A maior profundidade melhorou a acurácia de teste;
- Forte ajuste ao treino; generalização precisa de validação adicional.

AJUSTE DOS MODELOS



5 AJUSTE DE PARÂMETROS E SOBREAJUSTE

COMO EXECUTAR

- Instalar Python e as dependências do requirements.txt;
- Abrir o notebook e selecionar o kernel;
- Acessar o CSV disponibilizado no Google Drive;
- Executar as células em ordem.

```
# Carregando o dataset
url_dados = (
    "https://drive.google.com/uc?export=download"
    "&id=1er0sPjY51RymKrRkzZkjFOVwJ8PEZoAZ"
)

df = pd.read_csv(url_dados)
```

6 EXECUÇÃO E DEMONSTRAÇÃO

RESULTADOS



- **Comparação no fluxo principal:** base com nulos removidos.

Métrica	KNN, K = 3	Árvore sem limite
Acurácia	93,95%	95,89%
Precisão das falhas	32,17%	43,86%
Recall das falhas	71,88%	78,12%
F1 das falhas	44,44%	56,18%
Acurácia	83,30%	87,32%

LIMITAÇÕES E MELHORIAS

- Ajustar a imputação dos campos nulos somente no treino;
- Comparar os tratamentos nos mesmos registros de teste;
- Escolher parâmetros com validação cruzada;
- Avaliar poda e custos dos erros;
- Validar em novos dados antes da adoção.

8 PONTOS DE MELHORIA



OBRIGADA!

